

Estimación en áreas pequeñas

*Métodos indirectos basados en modelos: Método jerárquico
Bayes y método basado en modelos generalizados lineales
mixtos*

Andrés Gutiérrez
Comisión Económica para América Latina y el Caribe

2018

- ❶ *Método jerárquico Bayes bajo el modelo BHF*
- ❷ *Métodos basados en modelos lineales generalizados mixtos*

References

References

- (2018) Molina, Isabel. *Estudio de los límites de desagregación de datos en encuestas de hogares para subgrupos de población y áreas geográficas y los requerimientos para superarlos: Fase II*. CEPAL.

References

- (2018) Molina, Isabel. *Estudio de los límites de desagregación de datos en encuestas de hogares para subgrupos de población y áreas geográficas y los requerimientos para superarlos: Fase II*. CEPAL.

References

- (2018) Molina, Isabel. *Estudio de los límites de desagregación de datos en encuestas de hogares para subgrupos de población y áreas geográficas y los requerimientos para superarlos: Fase II*. CEPAL.
- (2015) Rao, J.N.K y Isabel Molina. *Small Area Estimation*. Second ed. Wiley Series in Survey Methodology.

Introducción

- De nuevo, estimadores para áreas basados en modelos se consideran modelos indirectos porque usan información de otras áreas

Introducción

- De nuevo, estimadores para áreas basados en modelos se consideran modelos indirectos porque usan información de otras áreas
- Estimadores basados en modelos incorporan la heterogeneidad que no puede ser explicada por las variables auxiliares coleccionadas

Introducción

- De nuevo, estimadores para áreas basados en modelos se consideran modelos indirectos porque usan información de otras áreas
- Estimadores basados en modelos incorporan la heterogeneidad que no puede ser explicada por las variables auxiliares coleccionadas
- Esto se realiza incorporando efectos aleatorios de las áreas en los modelos de interés

Método jerárquico Bayes bajo el modelo BHF

Método jerárquico Bayes bajo el modelo BHF

- Molina, Nandrum, y Rao (2014) propusieron el método jerárquico Bayes (*hierarchical Bayes*, HB), que no requiere el uso del bootstrap

Método jerárquico Bayes bajo el modelo BHF

- Molina, Nandrum, y Rao (2014) propusieron el método jerárquico Bayes (*hierarchical Bayes*, HB), que no requiere el uso del bootstrap
- El método reparametriza el modelo de errores anidados en términos del coeficiente de correlación intraclase
$$\rho = \sigma_u^2 / (\sigma_u^2 + \sigma_e^2)$$

Método jerárquico Bayes bajo el modelo BHF

- Molina, Nandrum, y Rao (2014) propusieron el método jerárquico Bayes (*hierarchical Bayes*, HB), que no requiere el uso del bootstrap
- El método reparametriza el modelo de errores anidados en términos del coeficiente de correlación intraclase
$$\rho = \sigma_u^2 / (\sigma_u^2 + \sigma_e^2)$$
- Considera distribuciones *a priori* para los parámetros $(\beta, \rho, \sigma_e^2)$

Método jerárquico Bayes bajo el modelo BHF

El modelo HB viene dado por:

1)

$$Y_{di}|u_d, \beta, \sigma_e^2 \stackrel{\text{ind}}{\sim} N(\mathbf{x}'_{di}\beta + u_d, \sigma_e^2 k_{di}^2), \quad i = 1, \dots, N_d,$$

Método jerárquico Bayes bajo el modelo BHF

El modelo HB viene dado por:

1)

$$Y_{di}|u_d, \beta, \sigma_e^2 \stackrel{\text{ind}}{\sim} N(\mathbf{x}'_{di}\beta + u_d, \sigma_e^2 k_{di}^2), \quad i = 1, \dots, N_d,$$

2)

$$u_d|\rho, \sigma_e^2 \stackrel{\text{iid}}{\sim} N\left(0, \frac{\rho}{1-\rho}\sigma_e^2\right), \quad d = 1, \dots, D,$$

Método jerárquico Bayes bajo el modelo BHF

El modelo HB viene dado por:

1)

$$Y_{di}|u_d, \beta, \sigma_e^2 \stackrel{\text{ind}}{\sim} N(\mathbf{x}'_{di}\beta + u_d, \sigma_e^2 k_{di}^2), \quad i = 1, \dots, N_d,$$

2)

$$u_d|\rho, \sigma_e^2 \stackrel{\text{iid}}{\sim} N\left(0, \frac{\rho}{1-\rho}\sigma_e^2\right), \quad d = 1, \dots, D,$$

3)

$$\pi(\beta, \rho, \sigma_e^2) \propto \frac{1}{\sigma_e^2}, \quad \epsilon \leq \rho \leq 1 - \epsilon, \sigma_e^2 > 0, \beta \in \mathbb{R}^p$$

donde $\epsilon > 0$ refleja la falta de información

Método jerárquico Bayes bajo el modelo BHF

- La distribución a priori de los parámetros del modelo se puede calcular en función de las distribuciones condicionadas usando la regla de cadena

Método jerárquico Bayes bajo el modelo BHF

- La distribución a priori de los parámetros del modelo se puede calcular en función de las distribuciones condicionadas usando la regla de cadena
- La densidad conjunta del parámetros $\theta = (\mathbf{u}', \beta', \sigma_e^2, \rho)'$ viene dada por

Método jerárquico Bayes bajo el modelo BHF

- La distribución a priori de los parámetros del modelo se puede calcular en función de las distribuciones condicionadas usando la regla de cadena
- La densidad conjunta del parámetros $\theta = (\mathbf{u}', \beta', \sigma_e^2, \rho)'$ viene dada por
- $$\pi(\mathbf{u}, \beta, \sigma_e^2, \rho | \mathbf{y}_s) = \pi_1(\mathbf{u} | \beta, \sigma_e^2, \rho, \mathbf{y}_s) \pi_2(\beta | \sigma_e^2, \rho, \mathbf{y}_s) \pi_3(\sigma_e^2 | \rho, \mathbf{y}_s) \pi_4(\rho | \mathbf{y}_s)$$

Método jerárquico Bayes bajo el modelo BHF

- La distribución a priori de los parámetros del modelo se puede calcular en función de las distribuciones condicionadas usando la regla de cadena
- La densidad conjunta del parámetros $\theta = (\mathbf{u}', \beta', \sigma_e^2, \rho)'$ viene dada por
- $$\pi(\mathbf{u}, \beta, \sigma_e^2, \rho | \mathbf{y}_s) = \pi_1(\mathbf{u} | \beta, \sigma_e^2, \rho, \mathbf{y}_s) \pi_2(\beta | \sigma_e^2, \rho, \mathbf{y}_s) \pi_3(\sigma_e^2 | \rho, \mathbf{y}_s) \pi_4(\rho | \mathbf{y}_s)$$
- Todas las distribuciones tienen forma conocida excepto π_4 , y generamos esos valores usando un método de rejilla

Método jerárquico Bayes bajo el modelo BHF

- Así, se pueden generar muestras de $\boldsymbol{\theta} = (\mathbf{u}', \boldsymbol{\beta}', \sigma_{\epsilon}^2, \rho)'$ directamente de la distribución a posteriori

Método jerárquico Bayes bajo el modelo BHF

- Así, se pueden generar muestras de $\theta = (\mathbf{u}', \beta', \sigma_e^2, \rho)'$ directamente de la distribución a posteriori
- Dado θ , las variables Y_{di} para todos los individuos verifican

$$Y_{di} | \theta \stackrel{\text{ind}}{\sim} N(\mathbf{x}'_{di}\beta + u_d, \sigma_e^2 k_{di}^2), \quad i = 1, \dots, N_d, \quad d = 1, \dots, D$$

Método jerárquico Bayes bajo el modelo BHF

- Así, se pueden generar muestras de $\theta = (\mathbf{u}', \beta', \sigma_e^2, \rho)'$ directamente de la distribución a posteriori
- Dado θ , las variables Y_{di} para todos los individuos verifican

$$Y_{di} | \theta \stackrel{ind}{\sim} N(\mathbf{x}'_{di}\beta + u_d, \sigma_e^2 k_{di}^2), \quad i = 1, \dots, N_d, \quad d = 1, \dots, D$$

- La densidad predictiva de \mathbf{y}_{dr} viene dada por

$$f(\mathbf{y}_{dr} | \mathbf{y}_s) = \int \prod_{i \in r_d} f(Y_{di} | \theta) \pi(\theta | \mathbf{y}_s) d\theta,$$

Método jerárquico Bayes bajo el modelo BHF

- Finalmente, el estimador HB viene dado por

$$\hat{\delta}_d^{HB} = E_{\mathbf{y}_{dr}}(\delta_d | \mathbf{y}_s) = \int \delta_d(\mathbf{y}_d) f(\mathbf{y}_{dr} | \mathbf{y}_s) d\mathbf{y}_{dr}$$

lo que estimamos usando una simulación Monte Carlo

Método jerárquico Bayes bajo el modelo BHF

- Finalmente, el estimador HB viene dado por

$$\hat{\delta}_d^{HB} = E_{\mathbf{y}_{dr}}(\delta_d | \mathbf{y}_s) = \int \delta_d(\mathbf{y}_d) f(\mathbf{y}_{dr} | \mathbf{y}_s) d\mathbf{y}_{dr}$$

lo que estimamos usando una simulación Monte Carlo

- Generamos muestras de la distribución a posteriori $\pi(\boldsymbol{\theta} | \mathbf{y}_s)$

Método jerárquico Bayes bajo el modelo BHF: proceso Monte Carlo

- Primero, generamos un valor $\rho^{(a)}$ de $\pi_4(\rho|\mathbf{y}_s)$ con un método de Rejilla

Método jerárquico Bayes bajo el modelo BHF: proceso Monte Carlo

- Primero, generamos un valor $\rho^{(a)}$ de $\pi_4(\rho|\mathbf{y}_s)$ con un método de Rejilla
- Después, generamos $\sigma_e^{2(a)}$ de $\pi_3(\sigma_e^2|\rho^{(a)}, \mathbf{y}_s)$, $\beta^{(a)}$ de $\pi_2(\beta|\sigma_e^{2(a)}, \rho^{(a)}, \mathbf{y}_s)$ y $\mathbf{u}^{(a)}$ de $\pi_1(\mathbf{u}|\beta^{(a)}, \sigma_e^{2(a)}, \rho^{(a)}, \mathbf{y}_s)$

Método jerárquico Bayes bajo el modelo BHF: proceso Monte Carlo

- Primero, generamos un valor $\rho^{(a)}$ de $\pi_4(\rho|\mathbf{y}_s)$ con un método de Rejilla
- Después, generamos $\sigma_e^{2(a)}$ de $\pi_3(\sigma_e^2|\rho^{(a)}, \mathbf{y}_s)$, $\beta^{(a)}$ de $\pi_2(\beta|\sigma_e^{2(a)}, \rho^{(a)}, \mathbf{y}_s)$ y $\mathbf{u}^{(a)}$ de $\pi_1(\mathbf{u}|\beta^{(a)}, \sigma_e^{2(a)}, \rho^{(a)}, \mathbf{y}_s)$
- Para cada de los A valores del vector $\boldsymbol{\theta}$, generamos los valores de los individuos afuera de la muestra $\mathbf{y}_{dr}^{(a)}$, y creamos el vector censal $\mathbf{y}_d^{(a)} = (\mathbf{y}'_{ds}, (\mathbf{y}_{dr}^{(a)})')'$

Método jerárquico Bayes bajo el modelo BHF:

- Para cada vector censal, producimos $\delta_d^{(a)} = \delta_d(\mathbf{y}_d^{(a)})$

Método jerárquico Bayes bajo el modelo BHF:

- Para cada vector censal, producimos $\delta_d^{(a)} = \delta_d(\mathbf{y}_d^{(a)})$
- Se aproxima El estimador HB por

$$\hat{\delta}_d^{HB} = E_{\mathbf{y}_{dr}}(\delta_d | \mathbf{y}_s) \approx \frac{1}{A} \sum_{a=1}^A \delta_d^{(a)}$$

Método jerárquico Bayes bajo el modelo BHF:

- Para cada vector censal, producimos $\delta_d^{(a)} = \delta_d(\mathbf{y}_d^{(a)})$
- Se aproxima El estimador HB por

$$\hat{\delta}_d^{HB} = E_{\mathbf{y}_{dr}}(\delta_d | \mathbf{y}_s) \approx \frac{1}{A} \sum_{a=1}^A \delta_d^{(a)}$$

- La varianza se aproxima por

$$V(\delta_d | \mathbf{y}_s) \approx \frac{1}{A} \sum_{a=1}^A \left(\delta_d^{(a)} - \hat{\delta}_d^{HB} \right)^2$$

Método jerárquico Bayes bajo el modelo BHF:

- Para cada vector censal, producimos $\delta_d^{(a)} = \delta_d(\mathbf{y}_d^{(a)})$
- Se aproxima El estimador HB por

$$\hat{\delta}_d^{HB} = E_{\mathbf{y}_{dr}}(\delta_d | \mathbf{y}_s) \approx \frac{1}{A} \sum_{a=1}^A \delta_d^{(a)}$$

- La varianza se aproxima por

$$V(\delta_d | \mathbf{y}_s) \approx \frac{1}{A} \sum_{a=1}^A \left(\delta_d^{(a)} - \hat{\delta}_d^{HB} \right)^2$$

- Para un indicador FGT, el estimador HB se aproxima en la forma:

$$\hat{F}_{\alpha d}^{HB} \approx \frac{1}{A} \sum_{a=1}^A F_{\alpha d}^{(a)}$$

Resumen del estimador del método HB:

- Indicadores objetivos: Parámetros generales

Resumen del estimador del método HB:

- Indicadores objetivos: Parámetros generales
- Requerimientos de datos:

Resumen del estimador del método HB:

- Indicadores objetivos: Parámetros generales
- Requerimientos de datos:
 - Microdatos de las p variables auxiliares de la misma de la variable de interés

Resumen del estimador del método HB:

- Indicadores objetivos: Parámetros generales
- Requerimientos de datos:
 - Microdatos de las p variables auxiliares de la misma de la variable de interés
 - Área de interés obtenida de la misma encuesta

Resumen del estimador del método HB:

- Indicadores objetivos: Parámetros generales
- Requerimientos de datos:
 - Microdatos de las p variables auxiliares de la misma de la variable de interés
 - Área de interés obtenida de la misma encuesta
 - Microdatos de las p covariables a partir de un censo o registro administrativo

Resumen del estimador del método HB:

- Ventajas:

Resumen del estimador del método HB:

- Ventajas:
 - Basado en datos a nivel de individuo, lo que provee información más detallada

Resumen del estimador del método HB:

- Ventajas:
 - Basado en datos a nivel de individuo, lo que provee información más detallada
 - Se puede estimar cualquier indicador que es una función de la variable Y_{di}

Resumen del estimador del método HB:

- Ventajas:
 - Basado en datos a nivel de individuo, lo que provee información más detallada
 - Se puede estimar cualquier indicador que es una función de la variable Y_{di}
 - Es insesgado bajo el modelo si los parámetros son conocidos

Resumen del estimador del método HB:

- Ventajas:
 - Basado en datos a nivel de individuo, lo que provee información más detallada
 - Se puede estimar cualquier indicador que es una función de la variable Y_{di}
 - Es insesgado bajo el modelo si los parámetros son conocidos
 - Minimiza la varianza a posteriori

Resumen del estimador del método HB:

- Ventajas:

Resumen del estimador del método HB:

- Ventajas:
 - Resulta prácticamente igual al estimador EB

Resumen del estimador del método HB:

- Ventajas:
 - Resulta prácticamente igual al estimador EB
 - Una vez se ajusta el modelo, se puede estimar en subáreas sin reajustar el modelo

Resumen del estimador del método HB:

- Ventajas:
 - Resulta prácticamente igual al estimador EB
 - Una vez se ajusta el modelo, se puede estimar en subáreas sin reajustar el modelo
 - Una vez se ajusta el modelo, se puede estimar cualquier indicador sin reajustar el modelo

Resumen del estimador del método HB:

- Ventajas:

Resumen del estimador del método HB:

- Ventajas:
 - No se usa el procedimiento *Markov Chain Monte Carlo*, MCMC, al contrario de muchos procesos bayesianos

Resumen del estimador del método HB:

- Ventajas:
 - No se usa el procedimiento *Markov Chain Monte Carlo*, MCMC, al contrario de muchos procesos bayesianos
 - No requiere el uso de métodos bootstrap para estimar ECM, lo que disminuye el tiempo computacional

Resumen del estimador del método HB:

- Ventajas:
 - No se usa el procedimiento *Markov Chain Monte Carlo*, MCMC, al contrario de muchos procesos bayesianos
 - No requiere el uso de métodos bootstrap para estimar ECM, lo que disminuye el tiempo computacional
 - El cálculo de intervalos creíbles o cualquier otro resumen de la distribución es automático

Resumen del estimador del método HB:

- Desventajas:

Resumen del estimador del método HB:

- Desventajas:
 - Es basado en un modelo, por tanto es necesario comprobar dicho modelo

Resumen del estimador del método HB:

- Desventajas:
 - Es basado en un modelo, por tanto es necesario comprobar dicho modelo
 - No tiene en cuenta el diseño muestral

Resumen del estimador del método HB:

- Desventajas:
 - Es basado en un modelo, por tanto es necesario comprobar dicho modelo
 - No tiene en cuenta el diseño muestral
 - Puede ser seriamente afectado por atípicos aislados

Resumen del estimador del método HB:

- Desventajas:
 - Es basado en un modelo, por tanto es necesario comprobar dicho modelo
 - No tiene en cuenta el diseño muestral
 - Puede ser seriamente afectado por atípicos aislados
 - El método no se puede extender a un modelo más complejos sin perder algunas ventajas mencionadas, como el evitar los métodos MCMC por ejemplo

Métodos basados en modelos lineales generalizados mixtos

Métodos basados en modelos lineales generalizados mixtos

- Los modelos mixtos hasta ahora no dan predicciones entre $[0, 1]$

Métodos basados en modelos lineales generalizados mixtos

- Los modelos mixtos hasta ahora no dan predicciones entre $[0, 1]$
- Para estimar proporciones, sería útil usar un modelo que proporcione valores en ese rango

Métodos basados en modelos lineales generalizados mixtos

- Los modelos mixtos hasta ahora no dan predicciones entre $[0, 1]$
- Para estimar proporciones, sería útil usar un modelo que proporciona valores en ese rango
- Esto incluye la incidencia de pobreza F_{0d} , pero no la brecha de pobreza, F_{1d}

Métodos basados en modelos lineales generalizados mixtos

- Los modelos mixtos hasta ahora no dan predicciones entre $[0, 1]$
- Para estimar proporciones, sería útil usar un modelo que proporciona valores en ese rango
- Esto incluye la incidencia de pobreza F_{0d} , pero no la brecha de pobreza, F_{1d}
- Para hacer eso, es habitual usar un modelo lineal generalizado mixto (*generalized linear mixed models*, GLMM)

Métodos basados en modelos lineales generalizados mixtos

- Asumimos que

$$Y_{di}|v_d \sim \text{Bern}(p_{di}), \quad g(p_{di}) = \mathbf{x}'_{di}\boldsymbol{\alpha} + v_d$$

y

$$v_d \stackrel{iid}{\sim} N(0, \sigma_v^2), \quad i = 1, \dots, N_d, \quad d = 1, \dots, D$$

Métodos basados en modelos lineales generalizados mixtos

- Asumimos que

$$Y_{di}|v_d \sim \text{Bern}(p_{di}), \quad g(p_{di}) = \mathbf{x}'_{di}\boldsymbol{\alpha} + v_d$$

y

$$v_d \stackrel{iid}{\sim} N(0, \sigma_v^2), \quad i = 1, \dots, N_d, \quad d = 1, \dots, D$$

- v_d es el efecto de área d y $\boldsymbol{\alpha}$ es el vector de coeficientes de la regresión

Métodos basados en modelos lineales generalizados mixtos

- Asumimos que

$$Y_{di}|v_d \sim \text{Bern}(p_{di}), \quad g(p_{di}) = \mathbf{x}'_{di}\boldsymbol{\alpha} + v_d$$

y

$$v_d \stackrel{iid}{\sim} N(0, \sigma_v^2), \quad i = 1, \dots, N_d, \quad d = 1, \dots, D$$

- v_d es el efecto de área d y $\boldsymbol{\alpha}$ es el vector de coeficientes de la regresión
- $g : (0, 1) \rightarrow \mathbb{R}$ es la función link (biyectiva, con derivada continua)

Métodos basados en modelos lineales generalizados mixtos

- Asumimos que

$$Y_{di}|v_d \sim \text{Bern}(p_{di}), \quad g(p_{di}) = \mathbf{x}'_{di}\boldsymbol{\alpha} + v_d$$

y

$$v_d \stackrel{iid}{\sim} N(0, \sigma_v^2), \quad i = 1, \dots, N_d, \quad d = 1, \dots, D$$

- v_d es el efecto de área d y $\boldsymbol{\alpha}$ es el vector de coeficientes de la regresión
- $g : (0, 1) \rightarrow \mathbb{R}$ es la función link (biyectiva, con derivada continua)
- El link logístico, $g(p) = \log(p/(1 - p))$, el más utilizado

Métodos basados en modelos lineales generalizados mixtos: Método mejor predictor

- El mejor predictor, el que minimiza el ECM bajo el modelo, viene dado por

$$\tilde{P}_d^B(\boldsymbol{\theta}) = E(P_d | \mathbf{y}_{ds}; \boldsymbol{\theta}) = \frac{1}{N_d} \left\{ \sum_{i \in s_d} Y_{di} + \sum_{i \in r_d} E(Y_{di} | \mathbf{y}_{ds}; \boldsymbol{\theta}) \right\}$$

Métodos basados en modelos lineales generalizados mixtos: Método mejor predictor

- El mejor predictor, el que minimiza el ECM bajo el modelo, viene dado por

$$\tilde{P}_d^B(\boldsymbol{\theta}) = E(P_d | \mathbf{y}_{ds}; \boldsymbol{\theta}) = \frac{1}{N_d} \left\{ \sum_{i \in s_d} Y_{di} + \sum_{i \in r_d} E(Y_{di} | \mathbf{y}_{ds}; \boldsymbol{\theta}) \right\}$$

- En la práctica, obtenemos el predictor EB reemplazando θ por estimaciones consistentes, es decir

$$\hat{P}_d^{EB} = \tilde{P}_d^B(\hat{\boldsymbol{\theta}})$$

donde $\hat{\boldsymbol{\theta}}$ se encuentra ajustando el modelo GLMM a los datos muestrales $\mathbf{y}_s = (\mathbf{y}'_{1s}, \dots, \mathbf{y}'_{Ds})'$

Métodos basados en modelos lineales generalizados mixtos: Método mejor predictor

- Una manera de estimar $E(Y_{di}|\mathbf{y}_{ds}; \boldsymbol{\theta})$ sería utilizar el Teorema de Bayes y que las variables Y_{di} son independientes dado v_d

Métodos basados en modelos lineales generalizados mixtos: Método mejor predictor

- Una manera de estimar $E(Y_{di}|\mathbf{y}_{ds}; \boldsymbol{\theta})$ sería utilizar el Teorema de Bayes y que las variables Y_{di} son independientes dado v_d
- En este caso,

$$E(Y_{di}|\mathbf{y}_{ds}; \hat{\boldsymbol{\theta}}) = \frac{E\{h(\mathbf{x}'_{di}\boldsymbol{\alpha} + v_d)f(\mathbf{y}_{ds}|v_d); \hat{\boldsymbol{\theta}}\}}{E\{f(\mathbf{y}_{ds}|v_d); \hat{\boldsymbol{\theta}}\}}, \quad i \in r_d,$$

donde $h = g^{-1}$ es el link inverso

$$h(\mathbf{x}'_{di}\boldsymbol{\alpha} + v_d) = \exp(\mathbf{x}'_{di}\boldsymbol{\alpha} + v_d) / \{1 + \exp(\mathbf{x}'_{di}\boldsymbol{\alpha} + v_d)\} \text{ y}$$

$$f(\mathbf{y}_{ds}|v_d) = \prod_{i \in s_d} p_{di}^{Y_{di}} (1 - p_{di})^{(1-Y_{di})}$$

Métodos basados en modelos lineales generalizados mixtos: Método mejor predictor

- Podemos usar un proceso Monte Carlo para generar $v_d^{(r)} \sim N(0, \hat{\sigma}_v^2)$, $r = 1, \dots, R$

Métodos basados en modelos lineales generalizados mixtos: Método mejor predictor

- Podemos usar un proceso Monte Carlo para generar $v_d^{(r)} \sim N(0, \hat{\sigma}_v^2)$, $r = 1, \dots, R$
- Después, calculamos

$$E(Y_{di} | \mathbf{y}_{ds}; \hat{\boldsymbol{\theta}}) \approx \frac{R^{-1} \sum_{r=1}^R h(\mathbf{x}'_{di} \hat{\boldsymbol{\alpha}} + v_d^{(r)}) \hat{f}(\mathbf{y}_{ds} | v_d^{(r)})}{R^{-1} \sum_{r=1}^R \hat{f}(\mathbf{y}_{ds} | v_d^{(r)})}, \quad i \in r_d,$$

donde \hat{f} es la distribución condicionada $f(\mathbf{y}_{ds} | v_d)$ en $\hat{\boldsymbol{\theta}}$

Métodos basados en modelos lineales generalizados mixtos: Método mejor predictor



$$\tilde{P}_d^B(\boldsymbol{\theta}) = E(P_d | \mathbf{y}_{ds}; \boldsymbol{\theta}) = \frac{1}{N_d} \left\{ \sum_{i \in s_d} Y_{di} + \sum_{i \in r_d} E(Y_{di} | \mathbf{y}_{ds}; \boldsymbol{\theta}) \right\}$$

tiene ECM mínimo y es insesgado bajo el modelo lineal generalizado mixto

Métodos basados en modelos lineales generalizados mixtos: Método mejor predictor



$$\tilde{P}_d^B(\boldsymbol{\theta}) = E(P_d | \mathbf{y}_{ds}; \boldsymbol{\theta}) = \frac{1}{N_d} \left\{ \sum_{i \in \mathcal{S}_d} Y_{di} + \sum_{i \in r_d} E(Y_{di} | \mathbf{y}_{ds}; \boldsymbol{\theta}) \right\}$$

tiene ECM mínimo y es insesgado bajo el modelo linear generalizado mixto

- Sin embargo, el proceso que se ha descrito es computacionalmente intensivo debido a las réplicas Monte Carlo

Métodos basados en modelos lineales generalizados mixtos: método plug-in

- Existen estimadores que se obtienen directamente de la salida del software que estima el GLMM

Métodos basados en modelos lineales generalizados mixtos: método plug-in

- Existen estimadores que se obtienen directamente de la salida del software que estima el GLMM
- Cuando se hace la regresión, el software estima $\hat{\alpha}$ y $\hat{\nu}_d$

Métodos basados en modelos lineales generalizados mixtos: método plug-in

- Existen estimadores que se obtienen directamente de la salida del software que estima el GLMM
- Cuando se hace la regresión, el software estima $\hat{\alpha}$ y \hat{v}_d
- Se puede crear un estimador por el método de la analogía (*plug-in estimator*) que viene dado por:

$$\hat{p}_d^{PI} = \frac{1}{N_d} \left(\sum_{i \in s_d} Y_{di} + \sum_{i \in r_d} \hat{p}_{di} \right)$$

donde

$$\hat{p}_{di} = h(\mathbf{x}'_{di} \hat{\alpha} + \hat{v}_d)$$

Métodos basados en modelos lineales generalizados mixtos: método plug-in

- Existen estimadores que se obtienen directamente de la salida del software que estima el GLMM
- Cuando se hace la regresión, el software estima $\hat{\alpha}$ y \hat{v}_d
- Se puede crear un estimador por el método de la analogía (*plug-in estimator*) que viene dado por:

$$\hat{p}_d^{PI} = \frac{1}{N_d} \left(\sum_{i \in s_d} Y_{di} + \sum_{i \in r_d} \hat{p}_{di} \right)$$

donde

$$\hat{p}_{di} = h(\mathbf{x}'_{di} \hat{\alpha} + \hat{v}_d)$$

- El estimador plug-in no es insesgado a menos que la función link es lineal

Métodos basados en modelos lineales generalizados mixtos: método plug-in

- Aunque es más fácil calcular, el estimador plug-in no es insesgado a menos que la función link es lineal

Métodos basados en modelos lineales generalizados mixtos: método plug-in

- Aunque es más fácil calcular, el estimador plug-in no es insesgado a menos que la función link es lineal
- Sin embargo, el link logístico $g(p) = \log(p/(1 - p))$ es aproximadamente lineal para $p \in (0.2, 0.8)$

Métodos basados en modelos lineales generalizados mixtos: método plug-in

- Aunque es más fácil calcular, el estimador plug-in no es insesgado a menos que la función link es lineal
- Sin embargo, el link logístico $g(p) = \log(p/(1 - p))$ es aproximadamente lineal para $p \in (0.2, 0.8)$
- Debido a esta propiedad, se puede comprobar que el EB y plug-in de la proporción $P_d = \bar{Y}_d$ se parecen al EBLUP, $\hat{P}_d^{EBLUP} = \hat{\bar{Y}}_d^{EBLUP}$, basado en el modelo con errores anidados (BHF)

Métodos basados en modelos lineales generalizados mixtos: ECM bootstrap

El ECM del estimador EB o plug-in se puede estimar con un procedimiento bootstrap

1) Ajustar el modelo GLMM $Y_{di}|v_d \sim \text{Bern}(p_{di})$, $g(p_{di}) = \mathbf{x}'_{di}\boldsymbol{\alpha} + v_d$ a los datos de la muestra para obtener los estimadores $\hat{\sigma}_v^2$ y $\hat{\boldsymbol{\alpha}}$

$$v_d^{*(b)} \stackrel{iid}{\sim} N(0, \hat{\sigma}_v^2), \quad d = 1, \dots, D$$

Métodos basados en modelos lineales generalizados mixtos: ECM bootstrap

- 3) Generar el censo bootstrap $\mathbf{y}_d^{*(b)} = (Y_{d1}, \dots, Y_{dN_d})'$ en la siguiente forma:

$$Y_{di}^{*(b)} \stackrel{\text{ind}}{\sim} \text{Bern}(p_{di}^{*(b)}),$$

y

$$p_{di}^{*(b)} = h(\mathbf{x}_{di}'\hat{\alpha} + v_d^{*(b)}), \quad i = 1, \dots, N_d, \quad d = 1, \dots, D,$$

Calcular los verdaderos valores de los indicadores para el censo

$$P_d^{*(b)} = \bar{Y}_d^{*(b)}, \quad d = 1, \dots, D.$$

Métodos basados en modelos lineales generalizados mixtos: ECM bootstrap

- 3) Generar el censo bootstrap $\mathbf{y}_d^{*(b)} = (Y_{d1}, \dots, Y_{dN_d})'$ en la siguiente forma:

$$Y_{di}^{*(b)} \stackrel{\text{ind}}{\sim} \text{Bern}(p_{di}^{*(b)}),$$

y

$$p_{di}^{*(b)} = h(\mathbf{x}_{di}'\hat{\alpha} + v_d^{*(b)}), \quad i = 1, \dots, N_d, \quad d = 1, \dots, D,$$

Calcular los verdaderos valores de los indicadores para el censo

$$P_d^{*(b)} = \bar{Y}_d^{*(b)}, \quad d = 1, \dots, D.$$

- 4) Para cada área, extraer del censo los elementos de la muestra Y_{di} , $i \in s_d^{*(b)}$ para construir el vector $\mathbf{y}_{ds}^{*(b)}$ y, después, $\mathbf{y}_s^{*(b)} = ((\mathbf{y}_{1s}^{*(b)})', \dots, (\mathbf{y}_{Ds}^{*(b)})')'$ el vector con los valores en la muestra de todas las áreas

Métodos basados en modelos lineales generalizados mixtos: ECM bootstrap

- 5) Ajustar el modelo GLMM a los datos bootstrap $\mathbf{y}_s^{*(b)}$ y calcular $\hat{P}_d^{EB*(b)}$, $d = 1, \dots, D$

Métodos basados en modelos lineales generalizados mixtos: ECM bootstrap

- 5) Ajustar el modelo GLMM a los datos bootstrap $\mathbf{y}_s^{*(b)}$ y calcular $\hat{P}_d^{EB*(b)}$, $d = 1, \dots, D$
- 6) Repetir pasos 2-5 B veces. El estimador bootstrap de ECM viene dado por

$$mse_B(\hat{P}_d^{EB}) = B^{-1} \sum_{b=1}^B (\hat{P}_d^{EB*(b)} - P_d^{*(b)})^2$$

Resumen del predictor EB/plug-in basado en GLMM

- Indicadores objetivos: Proporciones o totales de una variable binaria (e.g. carencia o no de determinado bien o servicio)

Resumen del predictor EB/plug-in basado en GLMM

- Indicadores objetivos: Proporciones o totales de una variable binaria (e.g. carencia o no de determinado bien o servicio)
- Requerimientos de datos:

Resumen del predictor EB/plug-in basado en GLMM

- Indicadores objetivos: Proporciones o totales de una variable binaria (e.g. carencia o no de determinado bien o servicio)
- Requerimientos de datos:
 - Microdatos de las p covariables obtenidas de la misma encuesta de la variable de interés

Resumen del predictor EB/plug-in basado en GLMM

- Indicadores objetivos: Proporciones o totales de una variable binaria (e.g. carencia o no de determinado bien o servicio)
- Requerimientos de datos:
 - Microdatos de las p covariables obtenidas de la misma encuesta de la variable de interés
 - Áreas de interés obtenidas de la misma encuesta

Resumen del predictor EB/plug-in basado en GLMM

- Indicadores objetivos: Proporciones o totales de una variable binaria (e.g. carencia o no de determinado bien o servicio)
- Requerimientos de datos:
 - Microdatos de las p covariables obtenidas de la misma encuesta de la variable de interés
 - Áreas de interés obtenidas de la misma encuesta
 - Microdatos de las p covariables de un censo o registro. Esto es necesario para calcular la esperanza $E(Y_{di} | \mathbf{y}_{ds}; \boldsymbol{\theta})$

Resumen del predictor EB/plug-in basado en GLMM

- Ventajas:

Resumen del predictor EB/plug-in basado en GLMM

- Ventajas:
 - El número de observaciones usadas es el tamaño muestral, mucho mayor que el número de áreas

Resumen del predictor EB/plug-in basado en GLMM

- Ventajas:
 - El número de observaciones usadas es el tamaño muestral, mucho mayor que el número de áreas
 - El modelo GLMM incorpora heterogeneidad no explicada entre las áreas

Resumen del predictor EB/plug-in basado en GLMM

- Ventajas:
 - El número de observaciones usadas es el tamaño muestral, mucho mayor que el número de áreas
 - El modelo GLMM incorpora heterogeneidad no explicada entre las áreas
 - No se necesita conocer ninguna varianza, al contrario que para el modelo FH

Resumen del predictor EB/plug-in basado en GLMM

- Ventajas:

Resumen del predictor EB/plug-in basado en GLMM

- Ventajas:
 - El estimador del ECM bajo el modelo es un estimador estable y insesgado bajo el diseño (y bajo el diseño cuando el número de áreas es grande)

Resumen del predictor EB/plug-in basado en GLMM

- Ventajas:
 - El estimador del ECM bajo el modelo es un estimador estable y insesgado bajo el diseño (y bajo el diseño cuando el número de áreas es grande)
 - Se puede estimar en cualquier subárea sin reajustar el modelo

Resumen del predictor EB/plug-in basado en GLMM

- Ventajas:
 - El estimador del ECM bajo el modelo es un estimador estable y insesgado bajo el diseño (y bajo el diseño cuando el número de áreas es grande)
 - Se puede estimar en cualquier subárea sin reajustar el modelo
 - Se puede estimar en áreas no muestreadas

Resumen del predictor EB/plug-in basado en GLMM

- Desventajas:

Resumen del predictor EB/plug-in basado en GLMM

- Desventajas:
 - Es basado en un modelo y por tanto es necesario analizar el modelo (a través de los residuos, por ejemplo)

Resumen del predictor EB/plug-in basado en GLMM

- Desventajas:
 - Es basado en un modelo y por tanto es necesario analizar el modelo (a través de los residuos, por ejemplo)
 - No tiene en cuenta el diseño muestral y, por eso, no es insesgado bajo el diseño

Resumen del predictor EB/plug-in basado en GLMM

- Desventajas:
 - Es basado en un modelo y por tanto es necesario analizar el modelo (a través de los residuos, por ejemplo)
 - No tiene en cuenta el diseño muestral y, por eso, no es insesgado bajo el diseño
 - El uso de microdatos de un censo puede conllevar problemas de confidencialidad

Resumen del predictor EB/plug-in basado en GLMM

- Desventajas:
 - Es basado en un modelo y por tanto es necesario analizar el modelo (a través de los residuos, por ejemplo)
 - No tiene en cuenta el diseño muestral y, por eso, no es insesgado bajo el diseño
 - El uso de microdatos de un censo puede conllevar problemas de confidencialidad
 - El estimador ECM bootstrap *no* es insesgado bajo el modelo para el ECM bajo el modelo para un área concreta

Resumen del predictor EB/plug-in basado en GLMM

- Desventajas:

Resumen del predictor EB/plug-in basado en GLMM

- Desventajas:
 - El predictor EB (no el plug-in) es computacionalmente intensivo

Resumen del predictor EB/plug-in basado en GLMM

- Desventajas:
 - El predictor EB (no el plug-in) es computacionalmente intensivo
 - El ECM del estimador EB usando un proceso bootstrap es excesivamente intensivo, pero se puede cortar usando el plug-in

Resumen del predictor EB/plug-in basado en GLMM

- Desventajas:
 - El predictor EB (no el plug-in) es computacionalmente intensivo
 - El ECM del estimador EB usando un proceso bootstrap es excesivamente intensivo, pero se puede cortar usando el plug-in
 - Requiere un reajuste para verificar la propiedad “benchmarking”